改进 YOLOv8n 的桃子品质分级检测方法

房云爽[1]， 王希伦[2]， 黄英来[1]
（1. 东北林业大学 计算机与控制工程学院，哈尔滨 150040；2. 中国人民公安大学 信息与网络安全学院，北京 100038）

摘 要：针对小型桃园中桃子品质分级大多依赖人工、标准化程度低、水果品质分级相关算法复杂等问题，提出改进 YOLOv8n 的桃子品质分级检测模型（YOLOv8n-ABTW）。主干网络（Backbone）嵌入坐标注意力机制（CA），精确捕捉目标位置变化和特征关联；颈部网络（Neck）融合简化的双向特征金字塔网络（SBiFPN）和上下文转换模块（COT），实现跨尺度特征连接，充分挖掘桃子图像中的纹理、缺陷和位置变化等静态和动态上下文信息；采用具有动态聚焦机制的 Wise-IoU，减少低质量样本带来的惩罚。采集“冬雪蜜桃”和“玉妃”2 个品种 4 个等级共 8 个类别的图像1 226张，再数据增强至3 650张。在自制桃子品质分级数据集下的实验结果表明：该模型的 $\alpha_{mAP@0.5}$ 比基准模型提高了 2.1%，与其他模型相比 $\alpha_{mAP@0.5}$ 也均有提升，为实现桃子品质分级检测提供了可行的技术方法。

关键词：桃子品质分级；目标检测；注意力机制；双向特征金字塔网络；损失函数
DOI：10.15938/j.jhust.2026.02.008
中图分类号：TP391.41 **文献标志码**：A **文章编号**：1007-2683(2026)02-0086-11

Improved Peach Quality Grading Detection Method Based on YOLOv8n

FANG Yunshuang[1], WANG Xilun[2], HUANG Yinglai[1]
(1. College of Computer and Control Engineering, Northeast Forestry University, Harbin 150040, China;
2. School of Information Technology and Cybersecurity, People's Public Security University of China, Beijing 100038, China)

Abstract: In addressing the issues of manual dependency, low standardization levels, and algorithmic complexity in quality grading of peaches in small-scale peach orchards, an enhanced YOLOv8n-based model named YOLOv8n-ABTW is proposed. The backbone network incorporates a Coordinate Attention (CA) mechanism to precisely capture target position variations and feature correlations. The Neck network integrates a Simplified Bi-directional Feature Pyramid Network (SBiFPN) and a Context Transformation Module (COT) to achieve cross-scale feature connections, thoroughly exploiting both static and dynamic contextual information such as textures, defects, and positional variations in peach images. The Wise-IoU with a dynamic focusing mechanism is employed to mitigate the penalty imposed by low-quality samples. A dataset comprising 1 226 images across eight categories, representing two varieties ("Dongxue Mitao" and "Yufei") and four quality grades, was augmented to 3 650 images. Experimental results on a self-constructed peach quality grading dataset indicate that the proposed model's $\alpha_{mAP@0.5}$ has improved by 2.1% compared to the baseline model, and it also shows enhancements in $\alpha_{mAP@0.5}$ when compared to other models, providing a feasible technical approach for the detection of peach quality grading.

Keywords: peach quality grading; object detection; attention mechanism; bidirectional feature pyramid network; loss function

收稿日期：2024-08-06
基金项目：国家自然科学基金(32271781).
作者简介：房云爽(1999—)，女，硕士研究生；
王希伦(2003—)，男，本科生.
通信作者：黄英来(1978—)，男，博士，副教授，博士研究生导师，E-mail：NEFUHYL@163.com.

0　引　言

随着人工智能的不断发展,人工智能与农业生产相结合已成为农业信息化发展的主流,其中基于机器视觉的检测技术已广泛地应用于不同品种农产品的检测分选[1],并使其向智能农业、现代农业方向发展,具有很好的实际应用价值[2]。

我国桃产量高,但市场竞争力不足,这与桃子品质分级标准化程度不高有关。早期的水果主要通过人工进行分级,分级结果缺少客观性和准确性,且人力物力消耗很大[3]。随着水果分级技术的引入,部分水果采用机械分选,但由于分选速度较快,容易损伤水果外观[4]。随着图像处理技术和机器学习的发展,科研人员将传统图像处理、高光谱成像等技术与机器学习结合,用来实现水果品质的检测[5-9]。深度学习能够自动提取图片特征,在计算机视觉领域应用广泛[10]。将目标检测算法与农产品的分选结合已成为趋势,FAN 等[11]利用 CNN 深度学习和高性价比视觉模块分拣缺陷苹果;UNAY[12]提出深度学习苹果质量分级法,通过多光谱图像训练二维 CNN 进行品质分级;彭彦昆等[13]应用 PP-YOLO 模型处理苹果图像;刘欢[14]采用计算机视觉技术对六安脆桃进行分级,使用 EfficientDet 检测缺陷;阮子行等[15]提出优化卷积神经网络用于番茄品质分级,网络包含权重层、池化层及批量归一化与压缩激励模块。

近年来,学者们将注意力机制与水果品质检测结合。HUANG 等[16]提出了柑橘检测算法,通过加入注意力机制和自适应融合特征方法对目标检测模型进行改进;胡广锐等[17]构建了混洗注意力与双卷积层模块,提高了检测模型对背景与果实特征的提取能力;ZHANG 等[18]提出了基于 YOLOv5s 并引入坐标注意力机制和双向特征网络的轻量级网络,实现了复杂果园环境下火龙果的全天候检测;贾雪莹等[19]提出了 YOLOv7-CACT 模型,用于柑橘表面缺陷实时监测,改进后的平均精度均值达到 91.1%;LU 等[20]提出了检测模型 YOLO-FD 用于柑橘果皮缺陷检测,利用柑橘对称指数、圆度、倾斜角度判断柑橘果实形态,形态检测准确率为 91.42%。

从最初的机械分级,到传统图像处理中滤波算法、Roberts 算法、Prewitt 算法、Canny 算法和高光谱成像在分级中的应用,再到利用深度学习相关算法对水果进行品质分级检测,再到如今注意力机制与水果品质分级检测的结合,类球形水果品质分级检测一直在不断进步,解决了机械损伤、算法复杂、特征提取困难等问题,精度和效率均有一定提升。然而,在实际应用中仍面临一些挑战:①果实分级特征不显著导致的漏检和误检;②普通深度学习模型在获取浅层信息方面存在不足,影响检测精度;③外部因素(如光照干扰)导致的图像噪声问题,以及普通模型在利用上下文信息方面具有局限性,导致有效信息丢失;④低质量样本惩罚对模型泛化能力的影响;⑤水果品质分级检测在桃子上的应用相对较少,方法单一,操作复杂且计算效率低。针对上述问题提出以下解决方案:

1)构建了包含 2 个品种、4 个等级,共 8 个类别、3650 张图像的桃子品质分级数据集,丰富了桃子品种分类和品质分级的数据集;

2)提出了基于改进 YOLOv8n 的桃子品质分级检测模型(YOLOv8n-ABTW),融合 CA[21]注意力机制,将位置信息和通道信息结合,加强了对图像表面干扰信息的辨别;嵌入基于双向特征金字塔网络(BiFPN[22])简化的 SBiFPN,通过双向多尺度特征的融合,加强了信息提取的丰富性,减少了信息丢失和信息冗余;引入 COT[23]模块,通过静态和动态上下文的联系,减轻了小面积特征和光照对检测的干扰;将 CIoU 替换为具有动态聚焦机制的 Wise-IoU[24],减少了低质量示例的惩罚;

3)简化了桃子品质分级检测流程,本文提出的模型能够同步输出桃子的品种和品质等级信息,拓宽了模型的应用领域。

1　数据集采集与制作

1.1　数据集采集

数据集采集地点为山东省泰安市肥城市桃源镇刘培俭桃园,如图 1 所示。采摘山东地区夏季和冬季具有代表性的品种“玉妃”79 个和“冬雪蜜桃”75 个,数据采集设备采用搭载索尼 IMX700 传感器的摄像头。采用控制变量法,保证摄像头的高度、光照条件及桃子中心点的位置不变,通过旋转桃子来捕捉不同角度的图像,并通过翻转桃子来获取另一面的图像,最终获得了共 8 个类别的1 226张图片。



图 1 桃子采摘区域

Fig. 1 Peach picking area

1.2 数据集制作

中华人民共和国农业农村部 2009 年 12 月 22 日发布的《NY/T 1792 – 2009 桃等级规格》所规定的等级划分标准如表 1 所示,将超出表 1 中缺陷范围的果实定义为等外果。

采用图像处理技术提取桃子果皮的着色率以量化红色面积,故选用 HSV 模型中的色调分量来表征果皮红色着色率。色调值趋近于 0 或 360 度时,红色着色率较高,据此调整桃子等级分类。利用 LabelImg 工具对 2 个品种、4 个等级的桃子图像进行标注,形成 8 个类别,以供模型训练,各类别桃子图像如图 2 所示。

表 1 NY/T 1792 – 2009 桃等级规格

Tab. 1 NY/T 1792 – 2009 peach grade specification

项目		一级	二级	三级
颜色		红色,粉红色面积不低于规定的 3/4	红色,粉红色面积不低于规定的 1/2	红色,粉红色面积不低于规定的 1/4
缺陷	碰压伤	无	无	无
	梗洼处果皮损伤	无	总面积 < 0.5 cm^2	总面积 < 1.0 cm^2
	磨伤	无	允许轻微磨伤,总面积 < 0.5 cm^2	允许轻微不褐变的磨伤,总面积 < 1.0 cm^2
	雹伤	无	无	允许轻微雹伤磨伤,总面积 < 0.5 cm^2
	裂果	无	允许风干裂口有一处,总面积 < 0.5 cm^2	允许风干裂口有一处,总面积 < 1.0 cm^2
	虫伤	无	允许轻微虫伤有一处,总面积 < 0.03 cm^2	允许轻微虫伤,总面积 < 0.3 cm^2



等外果 一级果 二级果 三级果

(a) 玉妃



等外果 一级果 二级果 三级果

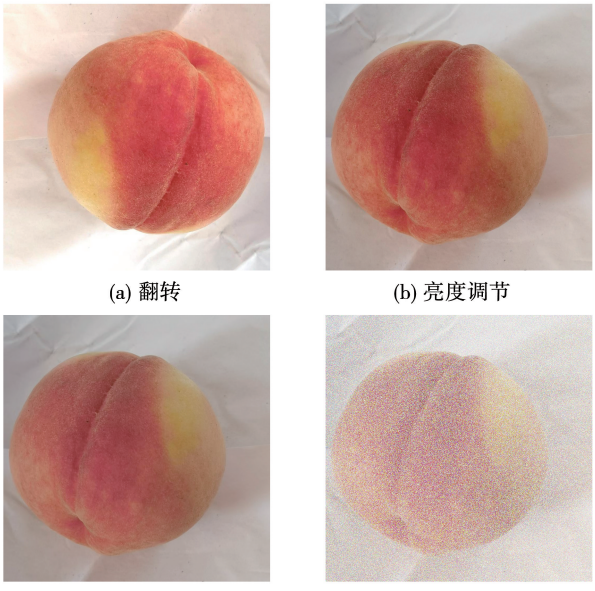
(b) 冬雪蜜桃

图 2 数据集类别

Fig. 2 Dataset categories

1.3　数据增强

为增加数据集的多样性,提升模型的鲁棒性及泛化能力,对数据集进行水平翻转、亮度调节、对比度调节、添加高斯噪声等数据增强处理,如图 3 所示。增强后的数据集包含3 650张图像数据,将数据集按 6∶2∶2的比例划分为训练集、测试集和验证集,具体划分细节如表 2 所示。



(a) 翻转　(b) 亮度调节　(c) 对比度调节　(d) 添加高斯噪声

图 3　数据增强

Fig. 3　Data augmentation

表 2　数据集划分(张)

Tab. 2　Dataset splitting

品种	等级	训练集	测试集	验证集	总和
冬雪蜜桃	等外果	189	62	62	313
	一级果	180	60	60	300
	二级果	306	102	102	510
	三级果	333	111	111	555
玉妃	等外果	221	73	73	367
	一级果	300	100	100	500
	二级果	324	108	108	540
	三级果	339	113	113	565

2　网络模型改进

2.1　YOLOv8 网络结构

YOLOv8 模型包括特征提取的主干网络(Backbone)、特征融合的颈部网络(Neck)和目标识别的检测头(Head)。Backbone 采用与 YOLOv5 相似的 CSPDarkNet 结构,但用 C2f 模块替代 C3 模块,以实现轻量化和性能提升。Neck 部分采用改进的 PANet 结构,增加了自下而上的路径,并去除了上采样中的卷积,同样使用 C2f 模块,C3 与 C2f 模块对比如图 4 所示。图中 CBS 为由卷积(Conv)、批归一化(BN)和 SiLU 激活函数组成的基本模块;S 为卷积步长;K 为卷积核大小;n 为 Bottleneck 模块的重复次数;Split 为特征图分割操作。检测头(Head)则采用了新的解耦头结构替代了传统的耦合头结构,提高了模型在目标类别和位置识别上的精度,显著增强了模型的检测性能。

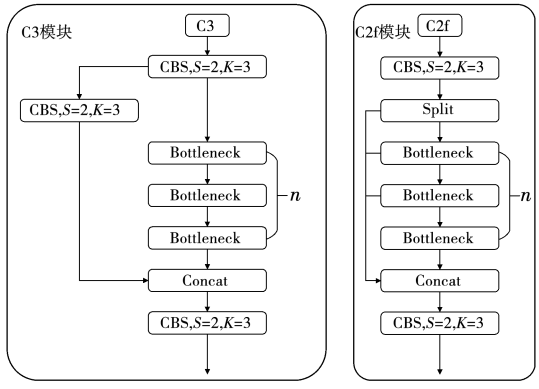


图 4　C3 和 C2f 结构对比图

Fig. 4　Comparison of C3 and C2f structures

2.2　YOLOv8 网络模型改进

针对 YOLOv8n 模型中的抗干扰能力弱、信息提取能力差、信息利用率低、特征融合能力差、目标对象浅层信息易丢失等问题,本文从主干网络、颈部网络、边界框回归损失函数等方面,增强模型对位置信息的感知能力和捕获能力;优化多尺度特征融合策略并简化特征金字塔网络;利用上下文信息提升自注意学习能力;降低低质量锚框的影响等角度改进模型。改进后的 YOLOv8n-ABTW 网络结构如图 5 所示。具体改进思路如下:

1)在主干网络的 C2f 模块后加入坐标注意力机制(coordinate attention mechanism, CA)[20],将位置信息嵌入到通道注意中,旨在提高模型对信息通道的敏感性和捕捉坐标位置信息的精准性,提升模型对桃子外部特征的感知能力。

2)针对桃子品质检测分级过程中,图像浅层特征信息提取时存在的信息丢失和信息冗余等问题,添加基于双向特征金字塔网络(bi-directional feature pyramid network, BiFPN)[21]简化的双向特征金字塔网络(SBiFPN),主要思想是跨尺度连接、加权特征融合和减少传输层数,旨在提高模型对不同分辨率目标的感知能力,优化该模块对浅层信息的感知。

3)针对桃子品质分级检测中存在的小面积特征检测不准确、光照干扰等问题,在颈部网络中添加

上下文转换模块(contextual transformer, COT)[22],将静态上下文和动态上下文融合,联系桃子图像中的上下文信息,提高自注意学习能力。

4)针对桃子品质分级检测过程中锚框定位不准确、低质量样本干扰等问题,将 CIoU 替换成具有动态聚焦机制的 Wise-IoU[23],旨在减少低质量锚框对模型性能的干扰,降低低质量样本惩罚,提升模型对普通质量的桃子锚框的定位能力,增强模型泛化能力。

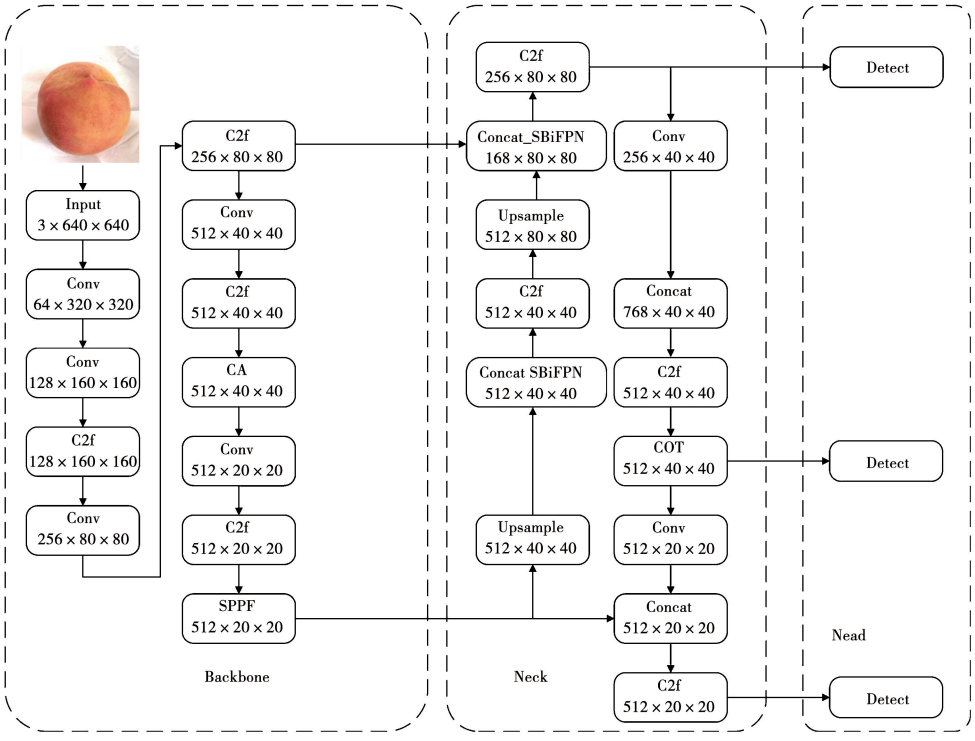


图 5 YOLOv8n-ABTW 网络结构示意图

Fig. 5 Architecture diagram of YOLOv8n-ABTW network

2.3 主干网络融合注意力机制

在目标检测任务中,为提升检测效率,通常引入 SE(squeeze and excitation)、CBAM(convolutional block attention module)、ECA(efficient channel attention)等注意力机制,但 SE 和 ECA 主要关注通道注意力,忽略了坐标信息;CBAM 同时引入通道注意力和空间注意力,但这 2 种注意力机制均需进行额外计算生成注意力权重,计算复杂且成本高,存在过拟合风险。桃子表面的果萼和纹理容易与磨伤混淆,YOLOv8n 在特征提取时难以区分这些细节,而 CA 不仅能通过坐标信息和通道注意力的融合增强模型对桃子的定位和识别能力,还避免了参数量过多、计算复杂性高和过拟合等问题。因此,为提高模型对纹理和缺陷的辨识能力,本文在 YOLOv8n 的主干网络中加入 CA 注意力机制,如图 6 所示。

CA 主要包括坐标信息嵌入和坐标注意力生成。为避免在整合空间坐标信息时位置信息丢失,CA 注意力将全局池化过程细分为一维特征的单独编码步骤。给定输入特征图 $\boldsymbol{X}$,对每个通道 C 分别沿着横、纵坐标应用池化核的 2 个空间范围$(H,1)$和$(1,W)$进行编码处理,其中$(H,1)$和$(1,W)$分别为水平空间范围和垂直空间范围的池化核。

在产生成对的方向感知特征图过程中,CA 能够同时识别 1 个空间维度上的远距离依赖性,并精确保持另 1 个维度上的位置信息。式(1)为高度为 h 的第 c 个通道的输出特征;式(2)为宽度为 w 的第 c 个通道的输出特征。式中:h 和 j 为高度坐标;i 和 w 为宽度坐标;x_c 为输入特征图 $\boldsymbol{X}$ 在第 c 个通道对应位置的像素值。

坐标注意力生成部分通过对位置信息的充分利用,准确突出感兴趣区域,有效捕获通道间的关系。具体实现如下:①基于式(1)~(2)输出的特征图,使用 1×1 卷积变换函数 F_1 分割特征图,通过非线性激活函数,输出 $\boldsymbol{f}$,得到中间特征图,如式(3)所示。式中:$[\cdot,\cdot]$为沿水平和垂直 2 个空间维度特征图的拼接运算;δ 为非线性激活函数;$\boldsymbol{f}$ 为输出的中间特征图。②将 $\boldsymbol{f}$ 沿空间维度拆分为 2 个独立的张量 $\boldsymbol{f}_h \in \mathbb{R}^{C/r\times H}$ 和 $\boldsymbol{f}_w \in \mathbb{R}^{C/r\times H}$,分别通过 1×1 卷积变换为 $\boldsymbol{F}_h$ 和 $\boldsymbol{F}_w$,利用 Sigmoid 函数(σ),得到与输入 $\boldsymbol{X}$ 通道数匹配的张量 $\boldsymbol{g}_h$ 和 $\boldsymbol{g}_w$,如式(4)~(5)所

示。③引入缩减比 r,以减少 $\boldsymbol{f}$ 的通道数量,对 $\boldsymbol{g}_h$ 和 $\boldsymbol{g}_w$ 进行扩展,用作注意力权重,将其与输入特征图进行对应位置元素相乘,最终得到注意力模块的输出 $y_c(i,j)$。式中:$x_c(i,j)$ 为输出特征图的原始像素值;$g_{c,h}(i)$ 和 $g_{c,w}(j)$ 分别为高度方向和宽度方向的注意力权重;$y_c(i,j)$ 为经过坐标注意力加权后的输出特征图在第 c 个通道 (i,j) 处的最终值。

$$z_{c,h}(h)=\frac{1}{W}\sum_{0\leqslant i<W}x_c(h,i) \tag{1}$$

$$z_{w,c}(h)=\frac{1}{H}\sum_{0\leqslant j<H}x_c(j,w) \tag{2}$$

$$\boldsymbol{f}=\delta(F_1([z_{c,h}(h),z_{w,c}(h)])) \tag{3}$$

$$\boldsymbol{g}_h=\sigma(F_n(\boldsymbol{f}_h)) \tag{4}$$

$$\boldsymbol{g}_w=\sigma(F_w(\boldsymbol{f}_w)) \tag{5}$$

$$y_c(i,j)=x_c(i,j)g_{c,h}(i)g_{c,w}(j) \tag{6}$$

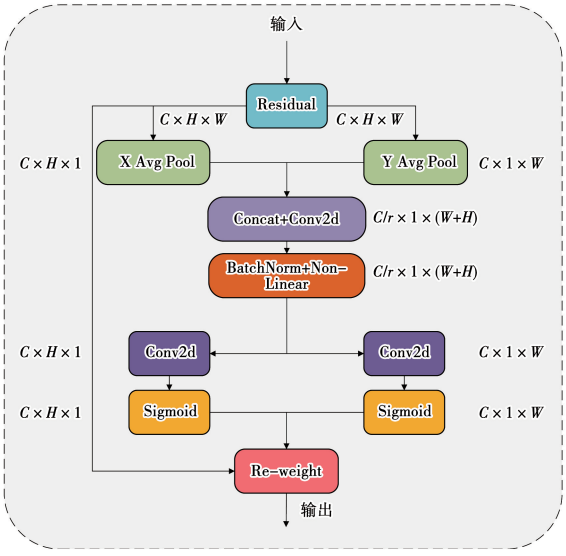


图 6　CA 坐标注意力机制结构图

Fig. 6　Architecture diagram of coordinate attention mechanism

CA 注意力机制将 2D 全局池化分解为 2 个一维编码,分别在水平和垂直方向上聚合特征,实现了长距离依赖的捕捉和位置信息的精确保留。在 YOLOv8n 中引入该注意力机制有利于模型对桃子品质分级的特点进行精准定位和识别,使模型能够更准确分辨不同品质级别的桃子,从而提高模型的检测精度。

2.4　简化的双向多尺度特征融合

在桃子品质的分级检测过程中,像素级浅层图像信息对桃子的分级特征识别也至关重要。双向特征金字塔网络(BiFPN)的核心思想是跨尺度连接和加权特征融合,解决了传统特征金字塔网络在特征提取过程中存在的信息丢失和冗余问题,但是多层传输造成了浅层信息的丢失。因此,本文在保证检测准确率的前提下,借鉴了 LU 等[19]的简化思路设计了减少传输层数的双向特征金字塔网络(SBiFPN),简化后的结构如图 7 所示,图中空白圆圈代表未径加权、卷积等操作的当前层原始特征。

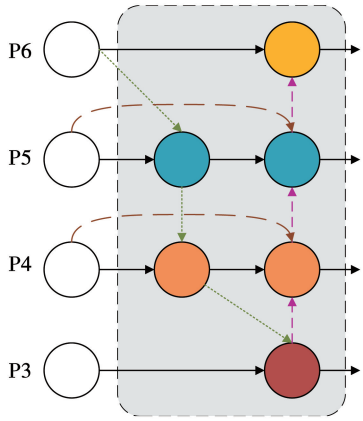


图 7　简化的 BiFPN 结构图

Fig. 7　Simplified BiFPN architecture diagram

SBiFPN 为每个输入特征分配了权重参数,使网络能够学习并区分不同输入特征的重要性。在集成了双向跨尺度连接和快速归一化融合的基础上,适当缩减层数,减少资源占用,优化浅层特征信息的融合。与 FPN 相比,增加了 1 个自下而上的路径聚合网络,并通过以下 4 种方法减少参数和计算量:①移除单输入节点;②当原始输入和输出节点处于同一级别时,增加 1 条连接线;③将每个双向路径看作 1 个特征网络层,并对这些层进行迭代;④减少特征传输的层数。高层特征 P_{in6} 上采样至同当前层 P_{in5} 相同尺寸,然后通过学习权重 w_1 和 w_2 进行加权求和并归一化,最后经卷积变换得到自上而下路径上第 5 层的中间特征 P_{td5},如式(7)所示。将当前层输入 P_{in5}、自上而下的中间特征 P_{td5} 以及低层输出 P_{out4} 下采样后,分别与可学习权重 w_1'、w_2'、w_3' 进行加权求和并归一化,最终经过卷积得到最终输出 P_{out5},如式(8)所示。式中,R_{Size} 为用于分辨率匹配的上采样或下采样操作;Conv 为用于特征处理的卷积操作;ϵ 为极小常数,用于稳定数值。

$$P_{td5}=\mathrm{Conv}\left(\frac{w_1P_{in5}+w_2R_{Size}(P_{in6})}{w_1+w_2+\epsilon}\right) \tag{7}$$

$$P_{out5}=\mathrm{Conv}\left(\frac{w_1'P_{in5}+w_2'P_{td5}+w_3'R_{Size}(P_{out5})}{w_1'+w_2'+w_3'+\epsilon}\right) \tag{8}$$

本文在颈部网络引入简化的双向特征金字塔网络(SBiFPN),通过简化传输层、自上而下和自下而上的特征聚合,提高了网络对桃子品质分级特征的学习效率。

2.5 融合上下文转换模块

针对桃子图像中纹理、缺陷等特征在图像中所占面积过小和光照干扰造成的上下文特征丢失问题,引入上下文转换(contextual transformer, COT)块,通过卷积挖掘键与键之间的纹理、缺陷和位置变化等上下文信息,促进自注意学习,提高输出的表达能力,以获取更多有关桃子纹理、缺陷等特征的上下文信息。COT 的结构如图 8 所示。

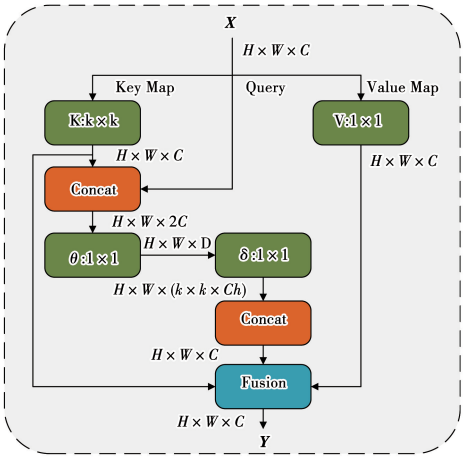


图 8 COT 结构图

Fig. 8 COT architecture diagram

COT 实质上是把卷积得到的静态上下文信息和动态上下文融合作为输出。具体实现过程如下:输入 2D 特征映射 $\boldsymbol{X}(\boldsymbol{X}\in\mathbb{R}^{H\times W\times C})$,分别把键、查询和值定义为 $\boldsymbol{K}=\boldsymbol{X}$、$\boldsymbol{Q}=\boldsymbol{X}$ 和 $\boldsymbol{V}=\boldsymbol{X}\boldsymbol{W}_v$。对 $k\times k$ 网络中的相邻键进行 $k\times k$ 组卷积操作,得到上下文键。$\boldsymbol{K}_1\in\mathbb{R}^{H\times W\times C}$ 的关键特征反映了局部相邻位置的静态上下文信息。然后将其与输入查询 $\boldsymbol{Q}$ 沿通道维度拼接,依次传输到 1 个包含 ReLU 激活函数和1 个不包含激活函数的 1×1 卷积(分别为 $\boldsymbol{W}_\theta$ 和 $\boldsymbol{W}_\delta$)中进行卷积归一化,其中 $\boldsymbol{W}_\theta$ 归一化后需进行 ReLU 激活,得到注意力矩阵 $\boldsymbol{A}$,如式(9)所示。

$$\boldsymbol{A}=[\boldsymbol{K}_1,\boldsymbol{Q}]\boldsymbol{W}_\theta\boldsymbol{W}_\delta \tag{9}$$

式中:$\boldsymbol{K}_1$ 为静态上下文键;$\boldsymbol{Q}$ 为查询;$\boldsymbol{W}_\theta$ 为带有 ReLU激活函数的 1×1 卷积;$\boldsymbol{W}_\delta$ 为不带激活函数的 1×1 卷积;$\boldsymbol{A}$ 为注意力矩阵。

将式(9)得到的注意力矩阵 $\boldsymbol{A}$ 与自注意力中的所有值 $\boldsymbol{V}$ 进行注意力加权聚合运算,得到特征映射 $\boldsymbol{K}_2$,即动态上下文表示,如式(10)所示。

$$\boldsymbol{K}_2=\boldsymbol{V}\circledast\boldsymbol{A} \tag{10}$$

式中:$\boldsymbol{V}$ 为对输入 $\boldsymbol{X}$ 通过 1×1 卷积变换得到的值;$\boldsymbol{K}_2$ 为动态上下文键;$\circledast$ 为注意力加权聚合。

2.6 动态聚焦机制的边界框回归损失

YOLOv8 使用了 CIoU,能够更好地处理非常规形状的目标,降低假正例率,但是 2 个框的长、宽构成的角度形成的弧的差异未能很好地定义,减缓了其收敛速度。此外,完整交叉面积的计算和修正因子的引入,增加了模型训练的计算负担,不能很好地处理桃子品质分级检测数据集中产生低质量锚框,降低了模型的泛化能力。Wise-IoU 引入动态非单调机制,设计了有效的梯度增益分配策略,计算成本主要在于聚焦系数的计算、IoU 损失的均值统计,使模型在训练过程中更加关注这些低质量样本,计算速度更快,从而提升了模型的泛化能力和整体性能[23]。因此,引入具有动态聚焦机制的 Wise-IoU 代替 CIoU。

Wise-IoU 根据距离度量构建了距离注意力,如式(11)~(12)所示,形成了包含两层注意力机制的 WIoUv1,降低了几何因素对低质量样本的惩罚,改善了低质量样本对泛化能力的影响。式中 $R_{\mathrm{WIoU}}\in[1,\mathrm{e})$,用于显著增强普通质量锚框的 L_{IoU};$L_{\mathrm{IoU}}\in[0,1]$,用于显著降低高质量锚框的 R_{WIoU}。此外,在锚框与目标框重合度较高时,该损失函数会减少中心点距离的权重,对不同质量锚框的关注度进行动态调整。

定义离群度 β 用于描述锚框质量,由 L^*_{IoU} 和 L_{IoU} 的比值表示,如式(13)所示。利用 β 构造了 1 个非单调聚焦系数 r,将其应用到 WIoUv1 中,得到了具有动态非单调 FM 的 WIoUv3,如式(14)所示。

$$L_{\mathrm{WIoUv1}}=R_{\mathrm{WIoU}}L_{\mathrm{IoU}} \tag{11}$$

$$R_{\mathrm{WIoU}}=\exp\left(\frac{(x-x_{\mathrm{gt}})^2+(y-y_{\mathrm{gt}})^2}{(W_{\mathrm{g}}^2+H_{\mathrm{g}}^2)^*}\right) \tag{12}$$

$$\beta=\frac{L^*_{\mathrm{IoU}}}{L_{\mathrm{IoU}}}\in[0,+\infty) \tag{13}$$

$$\left.\begin{aligned}L_{\mathrm{WIoUv3}}&=rL_{\mathrm{WIoUv1}}\\ r&=\frac{\beta}{\delta\alpha^{\beta-\delta}}\end{aligned}\right\} \tag{14}$$

式中:L_{WIoUv1} 为 Wise-IoU 第 1 版损失函数;R_{WIoU} 为距离注意力权重;x 和 y 为预测锚框的中心点坐标;x_{gt} 和 y_{gt} 为实际锚框的中心点坐标;W_{g} 和 H_{g} 分别为实际锚框的宽度和高度;L^*_{IoU} 和 L_{IoU} 分别为参考 IoU 损失和当前锚框的 IoU 损失;α 和 δ 为超参数,用于控制非单调聚焦系数 r 的曲线形状与峰值位置;L_{WIoUv3} 为 Wise-IoU 第 3 版损失函数,在第 1 版基础上引入了动态非单调聚焦机制。式(12)中 $*$ 的含义如下:将 W_{g} 和 H_{g} 从计算图中分离,停止梯度传播,不参与反向传播。防止 R_{WIoU} 产生阻碍收敛的梯度,使得 W_{g} 和 H_{g} 只作为常数参与前向计算,而不更新。

因此,引入 WIoUv3 能够实现训练过程中对不同质量锚框关注度的动态调整,降低高质量锚框竞争力,减小低质量样本产生的影响,从而更高效地训

练桃子品质分级的相关数据,避免产生过拟合。

3　结果与分析

3.1　环境配置与参数设置

采用同一实验环境和服务器平台,使用 Linux 操作系统、30 GB 运行内存、Intel(R) Xeon(R) CPU E5 - 2680 v4 @ 2.40 GHz * 7 核处理器、RTX 3090 图像处理器进行环境搭建,采用 Pytorch 1.11 深度学习框架和 Python 3.8 语言对模型进行处理,训练参数如表 3 所示。

表 3　训练参数

Tab.3　Training parameters

训练参数	参数值
批尺寸	16
轮次	300
输入图像尺寸	640 × 640
学习率	0.01
权重衰减率	0.000 5
优化器	SGD

3.2　性能评价指标

选择精确率 P、召回率 R、F1 分数 $F_{1\text{-score}}$、平均精度 α_{AP}、平均精度均值 α_{mAP}和模型参数量 5 个指标对模型进行评价。其中 $F_{1\text{-score}}$为精确率和召回率的调和平均数;$\alpha_{mAP0.5,0.95}$为 IoU 阈值在 0.5 到 0.95 之间,步长为 0.05 的平均精度;$\alpha_{mAP0.5}$为 IoU 阈值为 0.5 时的平均精度。相关计算如式(15) ~ (19)所示,式中:TP 为真正例;FP 为假正例;FN 为假反例;N 为类别数。

$$P=\frac{\mathrm{TP}}{\mathrm{TP}+\mathrm{FP}} \tag{15}$$

$$R=\frac{\mathrm{TP}}{\mathrm{TP}+\mathrm{FN}} \tag{16}$$

$$F_{1\text{-Score}}=\frac{2PR}{P+R} \tag{17}$$

$$\alpha_{AP}=\int_0^1 P(R)\,\mathrm{d}R \tag{18}$$

$$\alpha_{mAP}=\frac{\sum_{i=1}^{N}\alpha_{APi}}{N} \tag{19}$$

3.3　对比实验与结果分析

在自制桃子品质分级数据集上进行实验,其中训练集2 192张,验证集 729 张,包含“冬雪蜜桃”“玉妃”2 个品种、每个品种包含 4 个等级,共 8 个预测类别。本文对比了 Faster R-CNN、EfficientDet、YOLOv8n、YOLOv9n、YOLOv10n 和改进后的 YOLOv8n-ABTW 模型,在同一实验条件下进行训练和测试,实验结果如表 4 所示。

Faster R-CNN 将检测分为 2 个阶段:产生候选区域和对候选区域分类,主干网络是 VGG-16,召回率、$\alpha_{mAP0.5}$、$\alpha_{mAP0.5,0.95}$均低于 YOLOv8n,且参数量是 YOLOv8n 的 9.43 倍。EfficientDet 是 1 种单阶段检测模型,通过引入 BiFPN 增强特征融合,$\alpha_{mAP0.5}$、$\alpha_{mAP0.5,0.95}$低于 YOLOv8n,且参数量是 YOLOv8n 的 6 倍。YOLOv9n 通过整合可编程梯度信息(PGI)和广义高效聚合网络(GELAN),确保检测过程中关键信息的保留,召回率、$\alpha_{mAP0.5}$、$\alpha_{mAP0.5,0.95}$和 F1 分数均高于 YOLOv8n。但上述提升是以牺牲大量计算资源为前提,参数量是 YOLOv8n 的 10.44 倍,检测效率低于 YOLOv8n,推理速度较慢。YOLOv10n 主要通过去除非极大值抑制(NMS),提出一致的双重分配策略和整体效率 - 准确性驱动模型,优化检测效率。但与 YOLOv8n 相比,参数量变化不大,召回率却降低 1.8%,模型对真正例的识别能力明显下降。

表 4　对比实验结果

Tab.4　Comparative experiment results

模型	R /%	$\alpha_{mAP0.5}$ /%	$\alpha_{mAP0.5,0.95}$ /%	$F_{1\text{-score}}$ /%	参数量 /M
Faster R-CNN	86.2	87.6	83.5	86.9	28.3
EfficientDet	87.3	89.5	89.5	86.6	17.9
YOLOv8n	87.0	89.9	89.8	86.0	3.0
YOLOv9n	87.5	90.5	90.4	86.5	31.4
YOLOv10n	85.2	90.1	90.1	85.8	2.7
YOLOv8n-ABTW	89.0	92.0	92.0	88.4	3.1

YOLOv8n 既有较高的精确度和召回率,又有较少的参数量和较快的检测效率。因此,选择 YOLOv8n 为基准模型,并进行以下改进:在主干网络 C2f 模块后融合坐标注意力机制(CA),精准捕获坐标位置信息和特征之间的联系;在颈部网络中的 Concat 层融合 SBiFPN,通过自上而下和自下而上的特征融合,更快更精准地获取到目标图像浅层的特征信息;引入上下文转换模块,将纹理、缺陷等静态上下文信息与位置变化等动态上下文信息充分利用,促进自注意学习;将 CIoU 替换为 Wise-IoU,二者的性能对比如图 9 所示。由图可见,后者在桃子品质分级检测中展现出更快的收敛速度和更高的效率,表明在桃子品质分级检测任务中 Wise-IoU 提供了更好的优化路径和权重分配。图 10 为模型 $P-R$

曲线,由图可见,YOLOv8n-ABTW 模型在“冬雪蜜桃”一级果精确度、三级果召回率及 $\alpha_{mAP0.5}$ 指标上表现最优,而“玉妃”二级果指标最低,所有类别(all classes)的曲线最平滑,性能最稳定。与基准模型相比,YOLOv8n-ABTW 的召回率、$\alpha_{mAP0.5}$、$\alpha_{mAP0.5,0.95}$、F1 分数分别提高了 2.0%、2.1%、2.2%、2.4%。

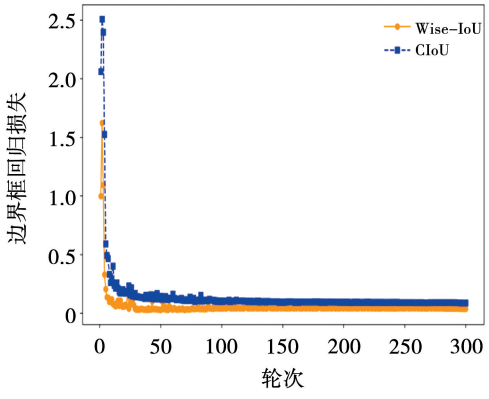


图 9 Wise-IoU 与 CIoU 性能对比

Fig. 9 Performance comparison between Wise-IoU and CIoU

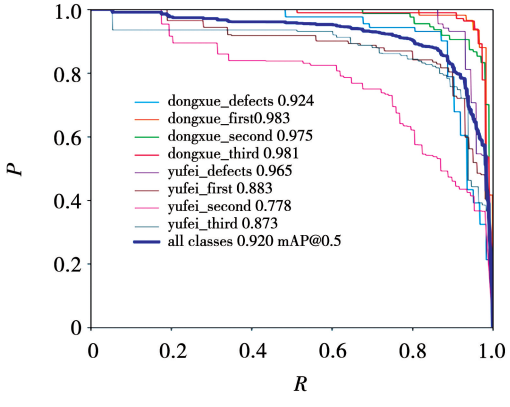


图 10 YOLOv8n-ABTW 模型精确度 – 召回率曲线

Fig. 10 YOLOv8n-ABTW model *P-R* curve

综上所述,YOLOv8n-ABTW 模型在面对桃子表皮缺陷不明显、纹理不清晰、低质量样本和光照干扰等挑战时,可在保证参数量不过度增加的同时显著提高识别精度,展现了更强的泛化能力,改进后模型的检测结果如图 11 所示。

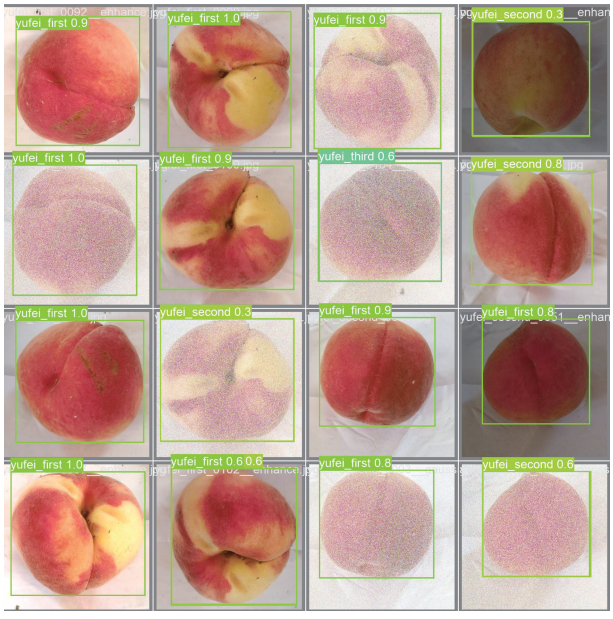


图 11 改进后模型的检测结果

Fig. 11 Detection results of the improved model

3.4 消融实验

为进一步验证引入模块对原网络性能提升的有效性[25-30],对基准模型和 4 种不同改进模型在同一数据集上进行消融实验,实验结果如表 5 所示。单独引入 CA 注意力机制、COT 模块、SBiFPN、替换 CIOU为 Wise-IoU、逐步添加 CA、COT、SBiFPN、Wise-IoU,与基准模型相比,$\alpha_{mAP0.5}$、$\alpha_{mAP0.5,0.95}$ 均有不同程度的提升。其中 YOLOv8n-ABTW 效果最佳,召回率、$\alpha_{mAP0.5}$、$\alpha_{mAP0.5,0.95}$ 和 F1 分数分别提升了 2.0%、2.1%、2.2%、2.4%。

表 5 消融实验结果

Tab. 5 Ablation experiment results

模型	R/%	$\alpha_{mAP0.5}$/%	$\alpha_{mAP0.5,0.95}$/%	$F_{1\text{-score}}$/%	参数量/M
YOLOv8n	87.0	89.9	89.8	86.0	3.0
YOLOv8n + CA	87.5	90.5	90.4	85.0	3.0
YOLOv8n + COT	85.5	90.3	90.3	86.1	3.0
YOLOv8n + SBiFPN	85.5	91.1	91.0	86.0	3.0
YOLOv8n + Wise-IoU	87.5	90.1	90.1	86.5	3.0
YOLOv8n + CA + COT	85.3	90.7	90.7	87.3	3.0
YOLOv8n + CA + COT + SBiFPN	85.2	91.4	91.3	87.3	3.1
YOLOv8n-ABTW	89.0	92.0	92.0	88.4	3.1

消融实验结果表明:YOLOv8n-ABTW 模型在参数量增加不明显的情况下,检测效果最好。这是由于 CA 充分利用了图像的坐标信息,增强了模型对于位置信息的感知能力;COT 模块通过增强上下文语义信息,提高了模型对小目标检测的准确性;SBiFPN 通过引入跨尺度连接,获取图像浅层信息,进而增强模型的特征融合能力;Wise-IoU 通过引入动态非单调机制,降低了模型对低质量示例的惩罚,令识别更加准确高效。

4　结　语

为应对桃子智能化品质分级和品种分类标准化的挑战,本文基于 YOLOv8n 提出了改进模型 YOLOv8n-ABTW。该模型在主干网络中整合了 CA 注意力机制,在颈部网络中结合了 SBiFPN 和 COT 模块,并将 CIoU 替换为 Wise-IoU,$\alpha_{\text{mAP0.5}}$ 达到了 92%,较基准模型提高了 2.1%。YOLOv8n-ABTW 能有效提升对桃子品质分级检测的效率,有利于桃产业的智能化和标准化发展。

未来将针对桃子品质分级检测时存在的图像获取不全面、桃子品种较少、阴影干扰等问题进行深入研究,尝试对桃子图像进行多角度采集,并将这些图像拼接成复合图像以供检测,模拟更真实的检测环境。还将丰富数据集桃子品种,扩大模型在实际生活中的应用范围。

参 考 文 献:

[1] 金睦皓,毛双,刘鹏凌. 我国桃产业出口贸易的现状分析及应对策略[J]. 江苏农业科学,2019,47(12):334.
JIN M H, MAO S, LIU P L. Analysis and Countermeasures of China's Peach Industry Export Trade[J]. Jiangsu Agricultural Sciences, 2019,47(12):334.

[2] 黄英来,李大明,吕鑫,等. 改进 YOLOv4 算法的袋料香菇检测方法[J]. 哈尔滨理工大学学报,2022,27(4):23.
HUANG Y L, LI D M, LV X, et al. A Detection Method of Lentinus Edodes Based on Improved YOLOv4 Algorithm[J]. Journal of Harbin University of Science and Technology, 2022, 27(4):23.

[3] 何东健,杨青,薛少平,等. 果实表面颜色计算机视觉分级技术研究[J]. 农业工程学报,1998(3):207.
HE D J, YANG Q, XUE S P, et al. Computer Vision for Color Sorting of Fresh Fruits[J]. Transactions of the Chinese Society of Agricultural Engineering, 1998(3):207.

[4] 何文斌,魏爱云,明五一,等. 基于机器视觉的水果品质检测综述[J]. 计算机工程与应用,2020,56(11):10.
HE W B, WEI A Y, MING W Y, et al. Survey of Fruit Quality Detection Based on Machine Vision[J]. Computer Engineering and Applications, 2020,56(11):10.

[5] TAO Y, HEINEMANN P H, VARGHESE Z, et al. Machine Vision for Color Inspection of Potatoes and Apples[J]. Transactions of the ASAE, 1995, 38(5): 1555.

[6] SOFU M M, ER O, KAYACAN M C, et al. Design of an Automatic Apple Sorting System Using Machine Vision[J]. Computers and Electronics in Agriculture, 2016, 127: 395.

[7] 黄辰,费继友. 基于图像特征融合的苹果在线分级方法[J]. 农业工程学报,2017,33(1):285.
HUANG C, FEI J Y. Online Apple Grading Based on Decision Fusion of Image Features[J]. Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE), 2017, 33(1): 285.

[8] 黄锋华. 基于高光谱成像技术的油桃品质检测及品种判别研究[D]. 太原:山西农业大学,2016.

[9] 马高尚. 基于机器视觉的梨品质检测分级系统研究[D]. 秦皇岛:河北科技师范学院,2022.

[10] 黄英来,李宁,刘镇波,等. 改进轻量卷积网络在葡萄病害叶片的分类方法[J]. 哈尔滨理工大学学报,2023,28(3):1.
HUANG Y L, LI N, LIU Z B, et al. Improved Lightweight Convolutional Networks for Classification of Grape Diseased Leaves[J]. Journal of Harbin University of Science and Technology, 2023, 28(03):1.

[11] FAN S, LI J, ZHANG Y, et al. On Line Detection of Defective Apples Using Computer Vision System Combined with Deep Learning Methods[J]. Journal of Food Engineering, 2020, 286: 110102.

[12] UNAY, D. Deep Learning Based Automatic Grading of Bicolored Apples Using Multispectral Images[J]. Multimedia Tools and Applications, 2022,81(27):38237.

[13] 彭彦昆,孙晨,赵苗. 苹果品质动态无损感知及分级机器手系统[J]. 农业工程学报,2022,38(16):293.
PENG Y K, SUN C, ZHAO M. Dynamic Nondestructive Sensing and Grading Manipulator System for Apple Quality[J]. Transactions of the Chinese Society of Agricultural Engineering, 2022, 38(16): 293.

[14] 刘欢. 基于计算机视觉的六安脆桃分级研究[D]. 合肥:安徽农业大学,2023.

[15] 阮子行,黄勇,王梦,等. 基于改进卷积神经网络的番茄品质分级方法[J]. 江苏农业学报,2023,39(4):1005.

RUAN Z X, HUANG Y, WANG M, et al. Tomato Quality Grading Method Based on Improved Convolutional NeuralNetwork[J]. Jiangsu Journal of Agricultural Sciences, 2023, 39(4): 1005.

[16] HUANG H, HUANG T, LI Z, et al. Design of Citrus Fruit Detection System Based on Mobile Platform and Edge Computer Device[J]. Sensors, 2021, 22(1): 59.

[17] 胡广锐,周建国,陈超,等. 融合轻量化网络与注意力机制的果园环境下苹果检测方法[J]. 农业工程学报, 2022,38(19):131.
HU G R, ZHOU J G, CHEN C, et al. Fusion of the Lightweight Network and Visual Attention Mechanism to Detect Apples in Orchard Environment[J]. Transactions of the Chinese Society of Agricultural Engineering, 2022, 38(19): 131.

[18] ZHANG B, WANG R, ZHANG H, et al. Dragon Fruit Detection in Natural Orchard Environment by Integrating Lightweight Network and Attention Mechanism[J]. Frontiers in Plant Science, 2022, 13: 1040923.

[19] 贾雪莹,赵春江,周娟,等. 基于改进 YOLOv7 模型的柑橘表面缺陷在线检测[J]. 农业工程学报,2023,39(23):142.
JIA X Y, ZHAO C J, ZHOU J, et al. Online Detection of Citrus Surface Defects Using Improved YOLOv7 Modeling[J]. Transactions of the Chinese Society of Agricultural Engineering, 2023, 39(23): 142.

[20] LU J, CHEN W, LAN Y, et al. Design of Citrus Peel Defect and Fruit Morphology Detection Method Based on Machine Vision[J]. Computers and Electronics in Agriculture, 2024, 219: 108721.

[21] HOU Q, ZHOU D, FENG J. Coordinate Attention for Efficient Mobile Network Design[C]//2021 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2021: 13708.

[22] TAN M, PANG R, LE Q V. EfficientDet: Scalable and Efficient Object Detection[C]//2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2020: 10778.

[23] LI Y, YAO T, PAN Y, et al. Contextual Transformer Networks for Visual Recognition[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2023, 45(2): 1489.

[24] TONG Z, CHEN Y, XU Z, et al. Bounding Box Regression Loss with Dynamic Focusing Mechanism[J]. arxiv Preprint arxiv:2301.10051, 2023.

[25] 白汗章, 郭科, 常亮. 基于 GIM 技术和 YOLOv3 深度网络的三维电网建模及校验方法[J]. 沈阳工业大学学报, 2023, 45(3): 247.
BAI Hanzhang, GUO Ke, CHANG Liang. 3D Power Grid Modeling and Verification Method Based on GIM Technology and YOLOv3 Deep Network[J]. Journal of Shenyang University of Technology,2023, 45(3): 247.

[26] 金鑫,程凌森,赵亮, 等. 基于改进 YOLOv5 模型的智能变电站目标违规行为检测方法研究[J]. 电测与仪表,2024, 61(8): 179.
JIN Xin, CHENG Lingsen, ZHAO Liang, et al. Research on Intelligent Substation Target Violation Detection Method Based on Improved YOLOv5 Model[J]. Electrical Measurement & Instrumentation, 2024,61(8): 179.

[27] 刘敏, 姜亮, 田杨阳,等. 基于压缩图像与 YOLOv5 模型的架空输电线路缺陷检测技术[J]. 沈阳工业大学学报, 2025, 47(2): 152.
LIU Min, JIANG Liang, TIAN Yangyang, et al. Effect Detection Technology for Overhead Transmission Lines Based on Compressed Images and YOLOv5 Model[J]. Journal of Shenyang University of Technology, 2025, 47(2): 152.

[28] 仲伟峰, 弓越, 刘杰. 改进 YOLOv5 算法的卡通动漫人物脸部检测方法[J]. 哈尔滨理工大学学报, 2025, 30(4): 86.
ZHONG Weifeng, GONG Yue, LIU Jie. A Cartoon and Anime Character Facial Detection Method with Improved YOLOv5 Algorithm[J]. Journal of Harbin University of Science and Technology, 2025, 30(4): 86.

[29] 刘甜甜,彭放,卢伟龙,等. 基于 YOLOv7 的智能电网外部安全帽佩戴风险因素识别与检测[J]. 电测与仪表, 2024, 61(12): 42.
LIU Tiantian, PENG Fang, LU Weilong, et al. Identification and Detection of External Risk Factors for Safety Helmet Wearing in Smart Grid Based on YOLOv7[J]. Electrical Measurement & Instrumentation, 2024, 61(12): 42.

[30] 张志佳, 范莹莹, 邵一鸣, 等. 基于改进 YOLO v3 模型的多类交通标识检测[J]. 沈阳工业大学学报, 2023, 45(1): 66.
ZHANG Zhijia, FAN Yingying, SHAO Yiming, et al. Detection of Multi-type Traffic Signs Based on Improved YOLOv3 Model[J]. Journal of Shenyang University of Technology, 2023, 45(1):66.

(编辑:温泽宇)