# 融合自注意力与局部特征的遮挡行人重识别

王星月[1]， 任洪娥[1,2]， 陶 锐[1,3]
（1. 东北林业大学 计算机与控制工程学院，哈尔滨 150040；2. 黑龙江林业智能装备工程研究中心，哈尔滨 150040；
3. 呼伦贝尔学院，内蒙古 呼伦贝尔 021008）

**摘 要**：遮挡行人重识别（ReID）是一项旨在将遮挡人物图像与整体图像进行匹配的人物检索任务。为了解决遮挡问题，基于局部特征的方法已经被证明是有效的，因为它们提供了小粒度的信息，并且非常适合表示部分可见的人体。针对基于局部的模型训练存在的两个挑战：身体部位外观不像全局外观那样具有可辨别性与身体部位错位。LGFNet（local-global feature Net），基于自注意力机制，生成感受野大小自行调整的空间注意力图，进行全局－局部特征联合学习。LGFNet 在 Market-1501 数据集上，Rank-1 为 95.2%，mAP 为 86.5%。在 DukeMTMC-reID 数据集上 Rank-1 为 90.2%，mAP 为 80.3%。在 Occluded-Duke 数据集上 Rank-1 为 71.5%，mAP 为 60.9%。相较同类方法，准确率方面取得了显著提升。

**关键词**：遮挡行人重识别；计算机视觉；自注意机制；局部特征；三元组损失
**DOI**：10.15938/j.jhust.2025.03.003
**中图分类号**：TP751.1 **文献标志码**：A **文章编号**：1007－2683（2025）03－0024－08

# Occluded Person Re-Identification Method Based on Self-attention and Local Features

WANG Xingyue[1]， REN Honge[1,2]， TAO Rui[1,3]
（1. College of Computer and Control Engineering, Northeast Forestry University, Harbin 150040, China；
2. Heilongjiang Forestry Intelligent Equipment Engineering Research Center, Harbin 150040, China；
3. Hulunbuir University, Hulunbuir 021008, China）

**Abstract**：Occluded person re-identification (ReID) is a person search task aimed at matching occluded pedestrian images with their corresponding full-body images. Local feature-based methods have been demonstrated to be effective in addressing occlusion, as they provide fine-grained information and are especially suitable for representing partially visible body parts. However, training local feature-based models poses two challenges: body part appearance lacks discriminability compared to global appearance and body part misalignment. To address these challenges, this paper proposes LGFNet (local-global feature Net), a network model that combines global-local feature joint learning with spatial attention maps generated based on self-attention mechanisms. LGFNet allows for automatic adjustment of receptive field sizes. It achieves state-of-the-art results on three public datasets: Market-1501, DukeMTMC-reID, and Occluded-Duke. Specifically, LGFNet achieved Rank-1 accuracy of 95.2% and mAP of 86.5% on Market-1501, Rank-1 of 90.2% and mAP of 80.3% on DukeMTMC-reID, and Rank-1 of 71.5% and mAP of 60.9% on Occluded-Duke. These results demonstrate that LGFNet significantly improves accuracy compared to similar methods.

**Keywords**：occluded person re-identification; computer vision; self-attention mechanism; local features; triplet loss

**收稿日期**：2023－08－04
**基金项目**：黑龙江省自然科学基金（LH2020F040）；中央高校基本科研业务费专项资金资助项目（2572017PZ10）.
**作者简介**：王星月（1998—），女，硕士研究生；
陶 锐（1978—），男，博士，副教授.
**通信作者**：任洪娥（1962—），女，教授，博士研究生导师，E-mail：nefu_rhe@163.com.

## 0　引　言

行人重识别(person re-identification,ReID)[1-2]是计算机视觉领域的热门研究方向,主要解决跨摄像头下的行人的识别与检索问题。行人重识别技术在智能监控系统中发挥着重要的作用。卷积神经网络(convolution neural networks,CNN)的出现为 ReID 带来突破性的进展[3]。目前使用 CNN 的 ReID 技术通过叠加卷积层获取更高层语义信息取得了良好的成绩。但由于受到行人的姿态、遮挡、光线等因素的影响,ReID 技术仍然面临着很大的挑战。

为了解决上述问题,多数研究选择采用全局方法[4-5],将目标人物的全局特征学习为 1 个统一特征向量。然而由于障碍物遮挡和其他行人干扰等问题,全局学习的特征可能包含来自障碍物和其他行人的误导性外观信息。此外,基于局部特征的方法已经展现出效果[6]。这些方法通过产生多个局部特征向量来处理 ReID 任务。然而也涉及到非判别性局部外观问题,即两个具有不同身份的人他们的某些身体部位可能有非常相似的外表特征。

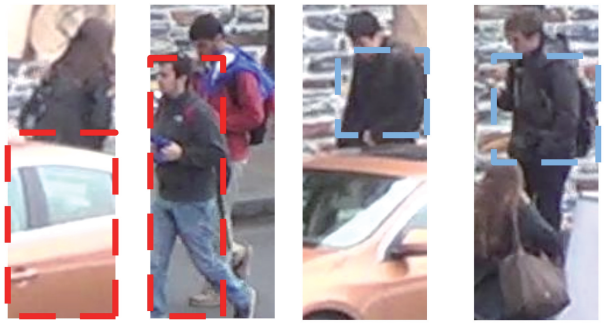
此外身体部位错位是影响 ReID 结果的另一个关键因素,身体部位错位可归结于以下两点:首先行人走路时会摆出各种姿势;其次由于行人检测技术的不完善,同一个人相同的身体部位在不同图像中会有不同比例。最近的研究试图利用人体的结构信息来提高性能[7-8],使用人体结构信息可以帮助 ReID 捕捉有区别性的局部视觉特征,如身体部位、人体姿势和人体属性等。例如,融合多尺度对比池化特征方法利用残差网络 ResNet50 提取行人图像的多尺度特征[9],并在网络的不同层上借助全局平均池化和全局最大池化来得到具有强判别性的对比池化特征。多尺度生成对抗网络方法使用低分辨率图像重构高分辨率的行人图像作为输入[10],有效融合不同尺度的图像细节信息,提升了行人图像去遮挡的性能。其他方法则借助语义分割算法、语义背景信息来提升 ReID 的性能[11-12]。以上方法利用了身体部位或多尺度特征,但这些方法只是手动调整了感受野大小,无法解决同一人在不同图像下身体比例大小不同的问题。

通过生成空间语义关系映射发现,图像不同位置之间存在两种类型的相互依赖关系:具有相似特征的位置具有更高相关性的外观关系,以及相互靠近的位置具有更高相关性的位置关系。在空间关系图的基础上,聚合不同位置的语义信息来更新特征图,使得网络针对不同姿势和比例的身体部位可以自适应地调整感受野大小。

基于此,本文提出双重监督训练的身体部位注意力模块,在空间维度对特征进行交互聚合,同时使用身份信息和粗略的人类解析标签,生成感受野大小自动调整的身体部位注意力图。将这个身体部位注意力模块和全局身份局部三元组损失相结合,构建了基于身体局部特征和全局特征的 LGFNet。对人体姿态变化,以及遮挡和非歧视性局部外观问题,LGFNet 具有鲁棒性。

## 1　空间自注意力机制

由于如图 1 所示的障碍物遮挡和其他行人干扰以及非判别性局部外观问题,使得现有的全局特征学习的行人重识别算法在进行特征学习时易受影响。针对此,本文提出基于空间自注意力搭建的网络模块(spatial attention,SA),增强 CNN 网络的特征表示能力。与提取固定几何结构特征的传统 CNN 不同,本文提出的网络可以根据输入图像中人物的姿势和身体部位的比例自适应地调整感受野。



(a) 障碍物和行人干扰　　(b) 非判别性局部外观

**图 1　遮挡行人重识别问题**

**Fig. 1　The challenge of occluded person re-identification**

如图 2 所示,假设卷积特征映射给出了 $F \in R^{C\times H\times W}$,其中 $C$、$H$ 和 $W$ 分别表示通道数、特征图的高度和宽度。首先将 $F$ 重塑为 $R^{C\times M}$,其中 $M(M=H\times W)$ 是空间特征的数量,然后对空间特征之间的相互依赖关系进行建模以生成语义关系图。考虑到外观信息和位置信息之间的联系,在聚合操作中使用生成的语义关系图来聚合相关联的空间特征。

通过计算输入特征图的任意两个位置之间的外观相似度,生成外观关系图。相邻位置的局部特征具有高相关性,由于它们的感受野经常重叠,相邻位置的窗口可以捕捉到更精确的外观特征。本文使用上下文信息获得更精确的外观相似特征。

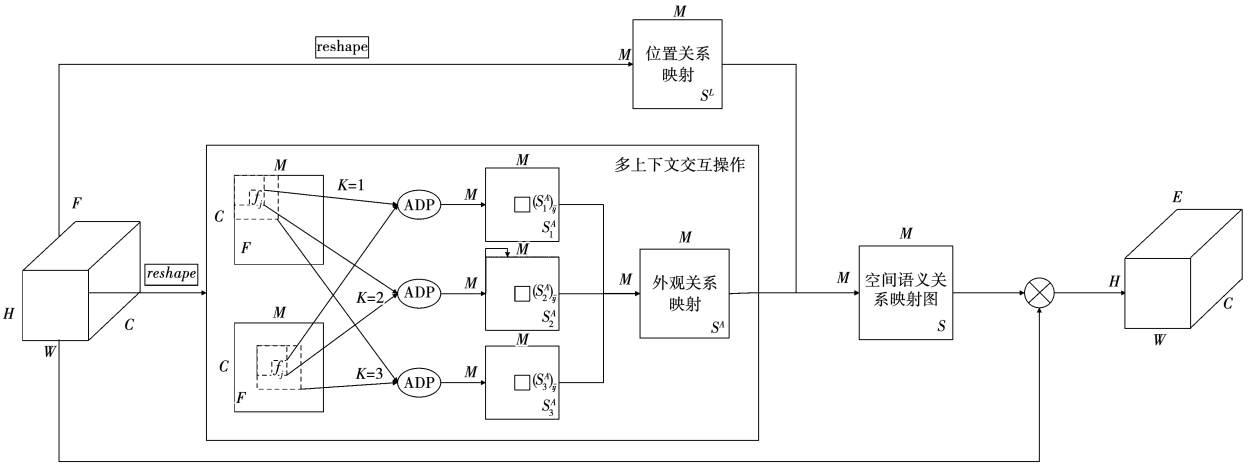



**图 2 SA 的多语境交互操作**

**Fig. 2 The multi-context interaction operation of SA**

$K\times K$ 表示特征图 $\boldsymbol{F}$ 第 $i$ 和第 $j$ 个空间位置的特征。为了计算 $\boldsymbol{f}_i$ 和 $\boldsymbol{f}_j$ 之间的外观相似性,首先分别提取 $i$ 和 $j$ 周围的 $K\times K$ 面积的 $\boldsymbol{P}_i$ 和 $\boldsymbol{P}_j$,将相应位置特征之间的点积结果进行累加,使用 softmax 对 $F$ 中的所有空间位置进行归一化,获得外观相似性:

$$(\boldsymbol{S}_{A,K})_{ij}=\frac{\exp\left(\sum_{k=1}^{K\times K}(\boldsymbol{p}_{i,t}^{\mathrm{T}}\boldsymbol{p}_{j,k})\right)}{\sum_{t=1}^{H\times W}\exp\left(\sum_{k=1}^{K\times K}(\boldsymbol{p}_{i,k}^{\mathrm{T}}\boldsymbol{p}_{t,k})\right)} \tag{1}$$

其中:$\boldsymbol{p}_{i,k}$和$\boldsymbol{p}_{j,k}$分别表示 $\boldsymbol{P}_i$ 和 $\boldsymbol{P}_j$ 在第 $k$ 个空间位置上的特征。通过融合上下文信息和抑制差异,关系图可以粗略地定位不同姿势和比例下的身体部位。因为只考虑了一个窗口大小(即 $k=1$),所以 $\boldsymbol{S}_A$ 是单上下文外观关系映射。多上下文外观关系映射 $\boldsymbol{S}_A$ 的计算如式(2):

$$\boldsymbol{S}_A=\mathrm{softmax}(\digamma(\boldsymbol{S}_{A,1},\cdots,\boldsymbol{S}_{A,N})) \tag{2}$$

其中:$N$ 表示上下文级别的数量,$\digamma$ 表示元素乘积的融合函数。多上下文交互可以缓解障碍物和行人干扰,以及非判别性局部外观这两个问题,并更精确地定位身体部位。

对于行人图像,相同身体部位的局部特征在空间上是相近的。基于此,本文引入了位置关系来充分利用空间结构信息,某一区域附近位置的特征具有更高的相关性。形式上,通过二维高斯函数计算空间特征 $\boldsymbol{f}_i$ 和 $\boldsymbol{f}_j$ 之间的位置关系,计算公式为

$$l_{ij}=\frac{1}{2\pi\sigma_1\sigma_2}\exp\left[-\frac{1}{2}\left(\frac{(x_j-x_i)^2}{\sigma_1^2}+\frac{(y_j-y_i)^2}{\sigma_2^2}\right)\right] \tag{3}$$

其中:$(x_i,y_i)$和$(x_j,y_j)$分别表示特征 $\boldsymbol{f}_i$ 和 $\boldsymbol{f}_j$ 的位置坐标,$(\sigma_1,\sigma_2)$是用于调整高斯函数的标准差。规范化 $l_{ij}$,使连接到 $\boldsymbol{f}_i$ 的位置关系值之和等于 1。生成的空间位置关系图 $\boldsymbol{S}_L$ 为

$$(\boldsymbol{S}_L)_{ij}=\frac{l_{ij}}{\sum_{t=1}^{H\times W}l_{it}} \tag{4}$$

$\boldsymbol{f}_i$ 和 $\boldsymbol{f}_j$ 之间的位置关系随着其空间距离的增加呈指数下降。值得注意的是,$\boldsymbol{S}_L$ 是基于输入图像的空间结构计算的,可以协助捕获更精准的视觉信息。

空间语义关系将外观相似性与位置关系结合起来,其表述如下:

$$\boldsymbol{S}=\mathrm{softmax}(\digamma(\boldsymbol{S}_A,\boldsymbol{S}_L)) \tag{5}$$

将基于语义关系图得到的空间特征进行聚合,如图 2 所示,计算聚集的特征映射 $\boldsymbol{E}_S\in R_{C\times M}$,通过 $\boldsymbol{F}$ 和 $\boldsymbol{S}$ 的转置之间的矩阵乘法:

$$\boldsymbol{E}_S=\boldsymbol{F}\boldsymbol{S}^{\mathrm{T}} \tag{6}$$

最终将 $\boldsymbol{E}_S$ 重塑为 $R^{C\times H\times W}$ 维度,以保持与输入特征图相同的尺寸,并将其结合到现有框架中。将注意力模块整合到现有架构中,如图 3 所示。SA 块定义为

$$Y=B_N(E)+F \tag{7}$$

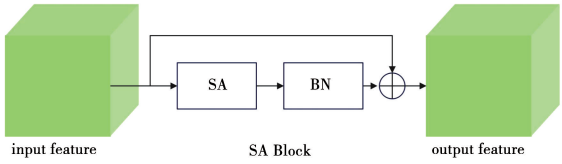



**图 3 SA 模块结构**

**Fig. 3 The structure of SA**

其中:$F$ 为输入特征图;$E$ 为式(6)中给出的 SA 模块的输出;$B_N$ 为 1 个批量标准化层[13],它根据输入调整比例,残差连接允许在任何预训练模型中插入新模块,而不会破坏其初始性能($B_N$ 的参数初始化为零)[14]。

## 2　全局 – 局部特征学习模块

### 2.1　逐像素部分分类器

身体局部注意力模块接收外观图 $G$ 作为输入,对于出现在外观图 $G$ 中的每个像素 $(w,h)$,逐像素部分分类器会预测它是否属于背景或 $K$ 个身体部位之一,这意味着共有 $K+1$ 个类别,其中为 0 的类别是背景。将参数 $\boldsymbol{P}\in R^{(K+1)\times C}$ 的 $1\times1$ 卷积层和 softmax 函数应用于特征图 $G$,以获得分类得分 $M\in R^{H\times W\times(K+1)}$,$\boldsymbol{M}_k$ 代表哪些像素属于哪些身体部位(或背景)。

$$M=\mathrm{softmax}(G\boldsymbol{P}^T) \tag{8}$$

### 2.2　局部特征学习

LGFNet 网络结构如图 4 所示,对于生成的特征图 $G$,如果空间位置 $(h,w)$ 属于 $T$ 个身体部分中的一个,或者属于背景,则人体解析标签 $Y(h,w)$ 被设置为 $\{1,\cdots,t\}$。对于给定的 $T$ 值,人类语义区域是手动定义的,例如,对于 $T=5$,定义以下语义区域:{头部、手臂、躯干、腿和脚}。

逐像素部分分类器采用身体部位注意力损失 $L_{pa}$ 监督,这是带有标签平滑的交叉熵损失,其中 $Y$ 是人类解析标签映射,$N$ 是批量大小,$\varepsilon$ 是标签平滑正则化率,$\boldsymbol{M}_t(h,w)$ 是空间位置 $(w,h)$ 处的部分 $T$ 的预测概率,$L_{pa}$ 如式(9)所示:

$$\left.\begin{aligned}L_{pa}&=-\sum_{t=0}^{T}\sum_{h=0}^{H-1}\sum_{w=0}^{W-1}q_t\log(\boldsymbol{M}_t(h,w))\\ \text{with}\quad q_t&=\begin{cases}1-\dfrac{N-1}{N}\varepsilon & \text{if}\quad Y(h,w)=t\\ \dfrac{\varepsilon}{N} & \text{otherwise}\end{cases}\end{aligned}\right\} \tag{9}$$

首先将 $T$ 个身体部分映射 $\{\boldsymbol{M}_1,\cdots,\boldsymbol{M}_t\}$ 合并在单个前景特征图 $\boldsymbol{M}_f\in R^{H\times W}$ 中:

$$\boldsymbol{M}_f(h,w)=\max(\boldsymbol{M}_1(h,w),\cdots,\boldsymbol{M}_t(h,w)) \tag{10}$$

然后进行外观特征图 $G$ 的 $T+1$ 全局加权平均池化(GWAP),以获得前景嵌入 $\boldsymbol{f}_f$ 和基于 $T$ 个身体部分的嵌入 $\{\boldsymbol{f}_1,\cdots,\boldsymbol{f}_t\}$:

$$\left.\begin{aligned}\boldsymbol{f}_i&=\frac{\sum_{h=0}^{H-1}\sum_{w=0}^{W-1}\boldsymbol{G}(h,w)\boldsymbol{M}_i(h,w)}{\sum_{h=0}^{H-1}\sum_{w=0}^{W-1}\boldsymbol{M}_i(h,w)}\\ &\forall i\in\{f,1,\cdots,T\}\end{aligned}\right\} \tag{11}$$

### 2.3　全局特征学习

对全局外观特征图 $G$ 进行全局平均池化(GAP),以获得全局嵌入 $\boldsymbol{f}_g(\boldsymbol{f}_g=\mathrm{GAP}(G))$,沿着通道维度连接 $T$ 个基于身体部位的特征,获得 $\boldsymbol{f}_c\in R^{(C\cdot T)}$,$\boldsymbol{f}_c\in\mathrm{concat}(\boldsymbol{f}_1,\cdots,\boldsymbol{f}_t)$。

### 2.4　全局 – 局部特征学习

全局 – 局部特征学习模块将 SA 模块生成的身体部位注意力图作为输入,并输出 ReID 目标的整体特征和基于身体部位的特征,身体部位注意力模块生成 $T$ 个空间特征图,突出显示输入图像的相应 $T$ 个预测身体部位。

本文的全局 – 局部特征学习模块获得 3 个整体嵌入 $\{\boldsymbol{f}_g,\boldsymbol{f}_f,\boldsymbol{f}_c\}$ 和 $T$ 个身体部分的嵌入 $\{\boldsymbol{f}_1,\cdots,\boldsymbol{f}_t\}$。训练阶段用于优化网络的总体目标函数公式如下:

$$L=L_{\mathrm{pa}}+L_{\mathrm{GLS}} \tag{12}$$

其中:$L_{\mathrm{pa}}$ 为用人类解析标签监督的身体部位注意力损失;$L_{\mathrm{GLS}}$ 为用身份标签监督的全局身份损失。实现身份标签监督模型训练,依赖于两个损失,常见的身份分类损失和自定义的部分平均三元组损失。

本文提出的 LGFNet 网络的训练策略为仅在全局特征上应用身份损失约束,并仅在局部特征上应用自定义的部分平均三元组损失,并将此策略称为全局局部协同训练策略 GLS:

$$\begin{aligned}L_{\mathrm{GLS}}&=L_{\mathrm{id}}+L_{\mathrm{tri}}=\\ &\sum_{i\in\{g,f,c\}}L_{\mathrm{CE}}(\boldsymbol{f}_i)+L_{\mathrm{tri}}^{\mathrm{parts}}(\boldsymbol{f}_1,\cdots,\boldsymbol{f}_t)\end{aligned} \tag{13}$$

其中:$L_{\mathrm{CE}}$ 为具有标签平滑和 BNNeck 技巧的交叉熵损失[4];$L_{\mathrm{tri}}^{\mathrm{parts}}$ 为部分平均三元组损失。$L_{\mathrm{id}}$ 通过整体嵌入 $\{\boldsymbol{f}_g,\boldsymbol{f}_c,\boldsymbol{f}_f\}$ 预测样本身份。

本文提出的部分平均三元组损失,依赖于两个样本 $i$ 和 $j$ 之间部位距离的平均值。该部位平均距离是使用所有基于身体部位的特征 $\{\boldsymbol{f}_1,\cdots,\boldsymbol{f}_t\}$ 联合计算:

$$d_{\mathrm{parts}}^{ij}=\frac{\sum_{t=1}^{T}d_{\mathrm{eucl}}(\boldsymbol{f}_t^i,\boldsymbol{f}_t^j)}{T} \tag{14}$$

其中 $d_{\mathrm{eucl}}$ 为欧氏距离。然后分别使用最难的正样本部分平均距离 $d_{\mathrm{parts}}^{\mathrm{ap}}$ 和最难的负样本部分平均距离 $d_{\mathrm{parts}}^{\mathrm{an}}$ 来计算:

$$L_{\mathrm{tri}}^{\mathrm{parts}}(\boldsymbol{f}_0^a,\cdots,\boldsymbol{f}_k^a)=[d_{\mathrm{parts}}^{\mathrm{ap}}-d_{\mathrm{parts}}^{\mathrm{an}}+\alpha]_+ \tag{15}$$

式中:从锚样本到最难的正样本和最难负样本的距离分别用 $d^{\mathrm{ap}}$ 和 $d^{\mathrm{an}}$ 表示;$\alpha$ 为三元组损失的边界值。

本文提出的部分平均三元组损失优化了相应部分之间的平均距离,使每个训练步骤都专注于具有最具鲁棒性和判别特征的局部,从而减轻了被遮挡和非判别性局部特征的影响。

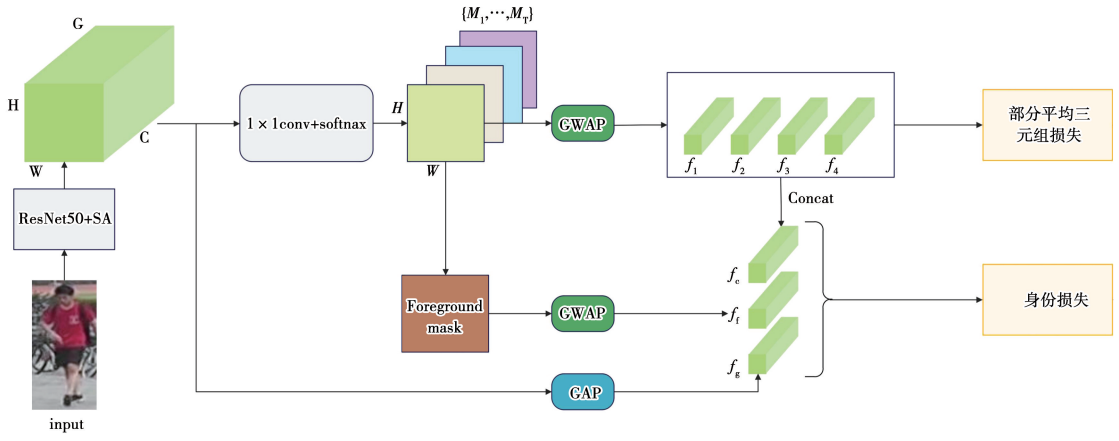



**图 4 LGFNet 网络结构**

**Fig. 4 The structure of LGFNet**

## 3 实验结果分析

### 3.1 数据集设置和评估方法

本文将在 3 个大规模的行人重识别基准数据集，即 Market1501、DukeMTMC-reID 和 Occluded-Duke 数据集上对本文的方法进行评估，通过消融实验展示每个模块对准确率的提升，并将本文的模型与其他先进方法进行比较。采用平均精度（mAP）和 Rank-1 作为评估指标。mAP（mean average precision），即平均精度均值，是评估算法性能的重要指标，指对于该类物体在不同置信度下的预测结果，将 Precision-Recall 曲线下面积（AUC）求出来，再对所有类别的 AUC 进行平均，得到平均精度均值。Rank-1 指的是算法在测试集上的 top-1 或第一名准确率。具体来说，Rank-1 是指，对于测试集中的每个查询图像，算法会从候选行人图像库中返回一个最匹配的行人图像，并将其与查询图像进行比对。如果查询图像的最匹配行人图像与真实标签是一致的，则该查询图像的 Rank-1 准确率为 1，否则为 0。

Market-1501 数据集是在清华大学某超市前采集的，总共使用了 6 个摄像头，包括五个高分辨率摄像头和一个低分辨率摄像头。该数据集包含1 501个行人的32 668个带注释的图像，其中来自 751 个行人的12 936幅图像用于训练，来自 750 个行人的19 732幅图像加上干扰用于查询。数据集中每个身份的图像最多由 6 个摄像头捕获，每个被标注的身份至少存在于 2 个摄像机中，每个图像信息包含摄像机 id 和帧号（时间戳）。

DukeMTMC-reID 是 DukeMTMC 数据集的一个子集，有 1404 个行人出现在两个以上的摄像机中，408 个行人只出现在一个摄像机中。选择 702 个标识作为训练集，剩余的 702 个标识作为测试集，每个图像包含其摄像机 id 和帧号（时间戳）。

Occluded-Duke 是一个基于 DukeMTMC-reID 数据集增强的数据集，用于评估行人重识别算法在遮挡场景下的性能。该数据集使用了离线遮挡方法和在线遮挡方法来增强 DukeMTMC-reID。在在线遮挡方法中，研究人员通过在摄像头前放置玻璃板并在玻璃板上绘制遮挡图案来模拟现实遮挡场景。在离线遮挡方法中，使用 Photoshop 集成的 Liquify 工具来改变图像中的行人外观，以模拟遮挡图像。在两种遮挡方法中，衣服上都会绑有彩色背包，用于区分同一身份的不同图像。该数据集一共包含了 8 个摄像头的数据，其中 6 个摄像头用于离线遮挡数据，2 个摄像头用于在线遮挡数据。每个摄像头都可以提供 675 个身份的不同行人图像。

### 3.2 实验设置与评价指标

实验过程在相同的软件和硬件环境下进行，以此保证实验结果的一致性。实验平台是 Ubuntu 21.10 操作系统，设备内存为 32 GB，CPU 为 Intel i7-10700K，显卡型号为 NVIDIA RTX3090，CUDA 版本 CUDA11，Python 版本为 Python3.6，PyTorch 版本为 PyTorch1.6。

本文使用加入 SA 模块后的 RestNet50 网络作为主干特征提取器，最后的全连接层和全局平均池化层被移除，并将最后一个卷积层的步幅从 2 改为 1。对于 Market1501 和 DukeMTMC-reID 数据集，身体部位的数量 $T$ 被设置为 5，对于 Occluded-Duke 数据集，$T$ 被设置为 8。训练过程主要采用了 BoT 中

的方法[4]。训练期间,将图像尺寸统一调整为 288 ×144,并随机裁剪成 256 ×128 的大小。训练期间 Batch Size 大小为 32,并选择 Adam 算法对模型进行优化,共训练 60 个 epoch。学习率初始化为 0.1,40 个 epoch 后降低为 0.01。SA 模块的 $\sigma_1$ 和 $\sigma_2$ 分别为 10 和 20、5 和 10。标签平滑正则化率 $\varepsilon$ 设定为 0.1,三元组损失边界值 $\alpha$ 设定为 0.3。

### 3.3　消融实验

本文在行人重识别的 3 个主流数据集 DukeMTMC-reID、Market-1501 和 Occluded-Duke 上进行了实验,通过对 SA 及 GLS 模块进行消融实验以评估它们对于模型性能的影响。首先对两个模块进行单独测试,然后将两个模块进行组合并测试,所得到的性能指标如表 1 所示。

**表 1　DukeMTMC-reID、Market-1501 和 Occluded-Duke 数据集消融实验对比结果**

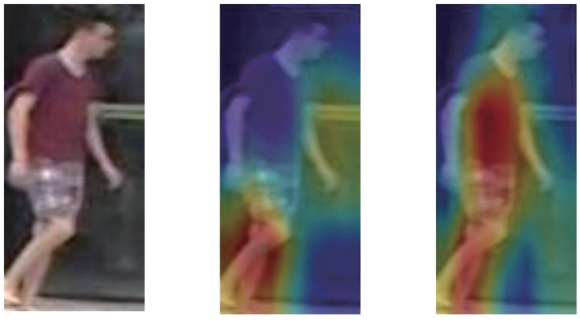
**Tab. 1　Comparison results of ablation experiments of Duke MTMC-reID、Market-1501 and Occluded-Duke datasets**

| 算法 | DukeMTMC-reID | | Market-1501 | | Occluded-Duke | |
|---|---|---|---|---|---|---|
| | Rank-1 | mAP | Rank-1 | mAP | Rank-1 | mAP |
| baseline | 86.4 | 76.4 | 94.5 | 85.9 | 51.4 | 44.7 |
| baseline + SA | 87.5 | 77.6 | 94.9 | 86.2 | 68.3 | 52.1 |
| baseline + GLS | 88.6 | 79.4 | 95.1 | 86.4 | 70.2 | 59.4 |
| baseline + SA + GLS | 90.2 | 80.3 | 95.2 | 86.5 | 71.5 | 60.9 |

通过实验所得的结果表明,在行人重识别的 baseline 模型中加入 SA 和 GLS 模块可以有效提升其在整体行人重识别及遮挡行人重识别任务中的准确性。这一结果印证了本文提出方法的有效性,表明使用所提出的模块可以改善行人重识别任务的性能表现。

为了深入研究 SA 模块对特征提取的影响,本文使用了 CAM 来可视化 SA 模块所学习的图像特征感受野。具体而言,本文通过可视化 SA 模块所生成的特征图中每个像素点的权重,将关注区域可视化成一张热力图,可以准确地了解每个感受野的覆盖范围和相对重要性。

为了展示 SA 模块对于不同情况具有良好的泛化性,图 5 ~ 7 展示了在非遮挡的 Market-1501 和 DukeMTMC-reID 数据集,以及遮挡的 Occluded-Duke 数据集通过 SA 模块学习的 CAM 可视化结果。结果表明,SA 模块对于特征提取表现出很好的性能,根据可视化结果,可以看到在 SA 模块中具有高关联性的图像区域被定义为有效的感受野。此外,视觉上观察到 SA 模块能够在不同场景中自适应地调整感受野的大小和范围,从而使模型鲁棒性和适应性更强。



(a) 原始图像　(b) ResNet50　(c) ResNet50+SA

**图 5　SA 模块在 Market-1501 数据集的可视化结果**

**Fig. 5　Visualization results of SA module in market-1501 dataset**



(a) 原始图像　(b) ResNet50　(c) ResNet50+SA

**图 6　SA 模块在 DukeMTMC-reID 数据集可视化结果**

**Fig. 6　Visualization results of SA modules in the Duke MTMC-reID dataset**



(a) 原始图像　(b) ResNet50　(c) ResNet50+SA

**图 7　SA 模块在 Occluded-Duke 数据集可视化结果**

**Fig. 7　Visualization results of SA modules in the Occluded-Duke dataset**

### 3.4 与现有方法比较

在表2中将本文的模型与其他行人重识别方法进行了比较,表格第1部分的方法[15-16]采用了与本文模型和BoT[4]相似的训练过程,并使用ResNet-50作为主干网络进行特征提取。

表格第2部分中的方法使用额外主干或分支的重架构[17]或更高级的主干网络[18],或使用局部特征转换方法[19]或自动数据增强[20]的方法。使用姿态估计模型直接作为局部注意力的方法时[15],由于无法调整感受野大小导致行人相关特征映射不够精确。相较于使用全局注意力解决遮挡[18],LGFNet使用全局-局部特征学习的方法取得了更优秀的表现。相较于使用其他模型的网络[16-17,19-20],准确度也有不同程度的提升。

实验分别在Market-1501数据集、DukeMTMC-reID数据集和Occluded-Duke数据集上进行验证。通过表2对比可知本文方法优于现有主流行人重识别方法,在Market-1501数据集上,Rank-1为95.2%,mAP为86.5%。在DukeMTMC-reID数据集上Rank-1为90.2%,mAP为80.3%。在Occluded-Duke数据集上Rank-1为71.5%,mAP为60.9%。相较于目前较优秀的SGAM,PGFA,PGFL等方法均有不同程度的提升。

**表2 本文方法和已有优秀方法在Market-1501、DukeMTMC-reID和Occluded-Duke数据集上的对比**

**Tab.2 Comparision results of the proposed method with existing excellent methods on Market-1501、DukeMTMC-Duke and Occluded-Duke datasets**

| 算法 | DukeMTMC-reID | | Market-1501 | | Occluded-Duke | |
|---|---|---|---|---|---|---|
| | Rank-1 | mAP | Rank-1 | mAP | Rank-1 | mAP |
| BoT[4] | 86.4 | 76.4 | 94.5 | 85.9 | 51.4 | 44.7 |
| SGAM[15] | 83.5 | 67.3 | 91.4 | 67.3 | 55.1 | 35.3 |
| PGFA[16] | 82.6 | 65.5 | 91.2 | 76.8 | 51.4 | 37.3 |
| PGFL[18] | 89.6 | 79.5 | 89.6 | 79.5 | 63.0 | 54.1 |
| SSGR[17] | 91.1 | 81.3 | 96.1 | 89.3 | 69.0 | 57.2 |
| SCLFT[19] | 95.5 | 89.0 | 90.7 | 82.1 | 69.8 | 60.8 |
| AAMANet[20] | 89.1 | 79.1 | 95.1 | 87.8 | 52.1 | 41.1 |
| Ours | 90.2 | 80.3 | 95.2 | 86.5 | 71.5 | 60.9 |

## 4 结 论

本文提出了一种新的行人重识别模型LGFNet(local-global feature Net)。设计了双重监督训练的身体部位注意力模块,它能够在空间维度对特征进行交互聚合,并使用身份信息和粗略的人类解析标签,生成感受野大小自动调整的身体部位注意力图,并将身体部位注意力模块和全局身份局部三元组损失相结合。

本文在3个公共数据集上评估了LGFNet的性能。在Market-1501数据集上,Rank-1为95.2%,mAP为86.5%。在DukeMTMC-reID数据集上Rank-1为90.2%,mAP为80.3%。在Occluded-Duke数据集上Rank-1为71.5%,mAP为60.9%。实验结果表明,本文提出的LGFNet模型在遮挡和非歧视性局部外观具有鲁棒性,并在遮挡和整体行人重识别数据集中都取得了良好的实验效果。

## 参 考 文 献:

[1] YE M, SHEN J, LIN G, et al. Deep Learning for Person Re-identification: A Survey and Outlook [J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2021, 44(6): 2872.

[2] 杨永胜, 邓淼磊, 李磊, 等. 基于深度学习的行人重识别综述[J]. 计算机工程与应用, 2022, 58(9): 51.
YANG Y, DENG M, LI L, et al. A Comprehensive Review of Deep Learning-based Pedestrian Re-identification [J]. Journal of Computer Engineering and Applications, 2022, 58(9): 51.

[3] 李勇, 杨德东, 毛宁, 等. 基于卷积神经网络的响应自

适应跟踪[J]. 液晶与显示,2018,33(7):596.
LI Y, YANG D, MAO N, et al. Response-adaptive Tracking Based on Convolutional Neural Networks[J]. Journal of Liquid Crystals and Displays, 2018, 33(7): 596.

[4] LUO H, GU Y, LIAO X, et al. Bag of Tricks and a Strong Baseline for Deep Person Re-identification[C]// Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops, 2019: 0.

[5] HERMANS A, BEYER L, LEIBE B. In Defense of the Triplet Loss for Person Re-identification[J]. arXiv Print arXiv:1703.07737, 2017.

[6] ZHANG Z, ZHANG H, LIU S. Person Re-identification Using Heterogeneous Local Graph Attention Networks [C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2021: 12136.

[7] 徐浩. 基于姿态特征的遮挡条件的行人重识别方法研究[J]. 自动化应用,2023,64(18):179.
XU H. Study on Pedestrian Re-identification Method Based on Pose Features under Occlusion Conditions[J]. Automation Application, 2023, 64(18): 179.

[8] 贾岩松,温显斌. 面向姿势多样性问题的行人重识别方法[J]. 天津理工大学学报,2023,39(4):46.
JIA Y, WEN X. Pedestrian Re-identification Methodfor Pose Diversity Problem[J]. Journal of Tianjin University of Technology, 2023, 39(4): 46.

[9] 刘晓蓉,李小霞,秦昌辉. 融合多尺度对比池化特征的行人重识别方法[J]. 计算机工程,2022,48(4):292.
LIU X, LI X, QIN C. Pedestrian Re-identification Method Based on Multiscale Contrastive Pooling Feature Fusion[J]. Computer Engineering, 2022, 48(4):292.

[10] 杨婉香,严严,陈思,等. 基于多尺度生成对抗网络的遮挡行人重识别方法[J]. 软件学报,2020,31(7):1943.
YANG W, YAN Y, CHEN S, et al. Re-identification Method for Occluded Pedestrians Based on Multi-scale Generative Adversarial Network[J]. Journal of Software, 2020, 31(7): 1943.

[11] KALAYEH M M, BASARAN E, GÖKMEN M, et al. Humansemantic Parsing for Person Re-identification [C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2018: 1062.

[12] 刘志刚,黄朝,谢东军,等. 抑制背景干扰的行人重识别方法[J]. 计算机辅助设计与图形学学报,2022,34(4):563.
LIU Z, HUANG C, XIE D, et al. Pedestrian Re-identification Method with Background Interference Suppression [J]. Journal of Computer-Aided Design & Computer Graphics, 2022, 34(4): 563.

[13] IOFFE S, SZEGEDY C. Batch Normalization: Acceleratingdeep Network Training by Reducing Internal Covariate Shift[C]//International Conference on Machine Learning. Pmlr, 2015: 448.

[14] HE K, ZHANG X, REN S, et al. Deep Residual Learningfor Image Recognition[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2016: 770.

[15] YANG Q, WANG P, FANG Z, et al. Focus on the Visibleregions: Semantic-guided Alignment Model for Occluded Person Re-identification[J]. Sensors, 2020, 20(16):4431.

[16] MIAO J, WU Y, LIU P, et al. Pose-guided Feature Alignment for Occluded Person Re-identification[C]//Proceedings of the IEEE/CVF inTernational Conference on Computer Vision, 2019: 542.

[17] ZHENG K, LAN C, ZENG W, et al. Pose-guided Feature Learning with Knowledge Distillation for Occluded Person Re-identification[C]//Proceedings of the 29th ACM International Conference on Multimedia, 2021: 4537.

[18] YAN C, PANG G, JIAO J, et al. Occluded Person Re-identification with Single-scale Global Representations [C]//Proceedings of the IEEE/CVF International Conferenceon Computer Vision, 2021: 11875.

[19] 朱松豪,赵云斌,焦淼. 融合空间相关性和局部特征转换器的遮挡行人重识别[J]. 南京邮电大学学报(自然科学版),2022,42(5):62.
ZHU S, ZHAO Y, JIAO M. Re-identification of Occluded Pedestrians Based on Fusion of Spatial Correlation and Local Feature Transformers[J]. Journal of Nanjing University of Posts and Telecommunications (Natural Science), 2022, 42(5): 62.

[20] 翟尤. 基于自动数据增强和混合注意力的遮挡行人重识别算法研究[D]. 重庆:西南大学,2023.

(编辑:温泽宇)